

RECUEIL DOCUMENTAIRE

L'Odyssée de l'IA

*Des fondements mathématiques aux modèles génératifs et aux
systèmes autonomes*

Rifka Bastoini · La Plateforme

1. Introduction

L'intelligence artificielle occupe aujourd'hui une place grandissante dans notre quotidien : on la retrouve dans les outils que nous utilisons, dans les entreprises, dans la recherche, mais aussi dans des domaines comme la santé, l'éducation ou la création. Son évolution est si rapide qu'il devient parfois difficile de distinguer ce qui relève d'une véritable rupture de ce qui prolonge simplement des idées plus anciennes.

Après une formation en mathématiques, j'ai choisi de poursuivre mon parcours dans le domaine de l'intelligence artificielle. Ce choix vient d'une volonté assez simple : comprendre une technologie qui nous entoure déjà et qui ne cesse d'évoluer. Je ne voulais pas seulement apprendre à utiliser les outils actuels, je voulais aussi comprendre ce qu'il y a derrière : pourquoi certaines méthodes ont fini par fonctionner, et pourquoi d'autres ont été abandonnées ou transformées.

L'IA actuelle n'est pas apparue d'un seul coup avec les assistants conversationnels. Elle vient d'une histoire beaucoup plus longue où se croisent logique, probabilités, optimisation, informatique et puissance de calcul. Cette histoire n'est pas linéaire non plus : elle connaît des périodes de progrès rapides, des impasses, et plusieurs changements de méthode.

Problématique : comment les idées mathématiques et informatiques ont-elles progressivement transformé la manière de construire l'intelligence artificielle, jusqu'aux systèmes actuels ?

2. Avant l'IA : rendre le raisonnement calculable

Bien avant les ordinateurs, une première question existait déjà : peut-on décrire un raisonnement avec des règles assez précises pour qu'il puisse être reproduit ? La logique formelle apporte une partie de la réponse. Au XIXe siècle, George Boole montre que des propositions logiques peuvent être manipulées avec une algèbre : des expressions comme ET, ou NON finissent par avoir une traduction mathématique. Cette logique booléenne deviendra plus tard un élément de base des circuits numériques [1].

En parallèle, la notion d'algorithme s'impose progressivement. Un algorithme n'est pas une formule magique : c'est une suite d'étapes qui transforme des données d'entrée en un résultat. Le mot vient du nom latinisé d'Al-Khwarizmi, mathématicien du IXe siècle. Ce principe de procédure est essentiel, car un ordinateur ne travaille pas avec une intention générale : il exécute des opérations décrites d'une manière précise [1].

Au XIXe siècle, Charles Babbage imagine, avec sa machine analytique, une machine mécanique programmable. Ada Lovelace comprend que l'intérêt du projet dépasse le simple calcul numérique : si l'on peut représenter une information sous une forme adaptée, une machine peut en principe lui appliquer des opérations. L'idée reste théorique, mais elle rapproche deux mondes jusque-là séparés, celui des mathématiques et celui de la machine programmable [1].

À ce stade, il n'existe toujours pas d'intelligence artificielle, mais le terrain est prêt : un raisonnement peut être formalisé, une tâche décrite comme une procédure et une machine imaginée pour l'exécuter.

Un même fil mathématique traverse toute cette histoire : la logique pour les règles, l'algèbre linéaire pour représenter les données et les paramètres, les probabilités pour gérer l'incertitude, et l'optimisation pour réduire l'erreur. Le XXe siècle va alors poser une nouvelle question : jusqu'où peut aller ce calcul ?

3. Turing, les premiers neurones et la naissance d'un domaine

En 1936, Alan Turing propose un modèle abstrait aujourd'hui appelé machine de Turing. Il ne s'agit pas d'un ordinateur au sens moderne, mais d'un modèle mathématique permettant de définir ce qu'une procédure mécanique peut calculer. C'est une étape fondamentale pour l'informatique théorique : avant de se demander si une machine peut être intelligente, il faut d'abord comprendre ce qu'une machine peut calculer.

En 1943, Warren McCulloch et Walter Pitts proposent un modèle très simplifié du neurone biologique. L'idée est étonnamment proche de ce que l'on retrouve encore aujourd'hui : plusieurs entrées sont combinées, puis une règle décide si l'unité s'active ou non. Dans une écriture moderne, on peut résumer un neurone par $y = \sigma(w^T x + b)$: les entrées x sont pondérées par w , on ajoute un biais b , puis une fonction d'activation σ transforme le résultat. Les réseaux actuels sont incomparablement plus grands, mais cette petite équation en contient déjà une partie de la logique.

Turing va ensuite déplacer la discussion vers l'intelligence elle-même. Dans son article de 1950, *Computing Machinery and Intelligence*, il propose l'Imitation Game, devenu le test de Turing : plutôt que de chercher à définir le mot « penser », il demande si le comportement d'une machine peut devenir suffisamment convaincant pour qu'un humain ne puisse plus facilement la distinguer d'une autre personne lors d'un échange écrit [2].

En 1956, l'atelier de Dartmouth donne enfin un nom au domaine. John McCarthy et plusieurs chercheurs y réunissent des travaux jusque-là dispersés entre logique, calcul, langage et apprentissage. L'expression artificial intelligence s'impose alors comme une manière de désigner ce projet scientifique [1]. La question change de statut : ce n'est plus seulement une réflexion théorique, c'est un programme de recherche.

4. Des règles écrites par l'humain à l'apprentissage à partir des données

Les premières décennies de l'IA sont dominées par une approche dite symbolique : représenter explicitement les connaissances sous forme de symboles, de faits et de règles. Un système qui connaît la règle « si A et B, alors C » peut enchaîner des déductions. Cette approche donne de bons résultats lorsque le problème est clairement défini ; elle mène aux premiers programmes de démonstration automatique, aux jeux, puis aux systèmes experts [1].

Le problème apparaît dès qu'on sort d'un environnement propre. Le monde réel contient des exceptions, des informations incomplètes, et beaucoup trop de situations pour que toutes les règles soient écrites à la main. Les ambitions très fortes des années 1950 et 1960 se heurtent aussi aux limites du matériel disponible, et les financements diminuent à plusieurs reprises : on parlera plus tard d'« hivers de l'IA » pour décrire ces périodes de désillusion [1].

Une autre idée va progressivement prendre le dessus : au lieu d'écrire la solution, on donne des exemples à la machine afin qu'elle ajuste elle-même ses paramètres. C'est le principe du machine learning. Le perceptron de Frank Rosenblatt, à la fin des années 1950, en fait partie, mais les réseaux de neurones restent longtemps difficiles à entraîner efficacement, et il faudra attendre plusieurs décennies pour que l'idée tienne ses promesses.

Le retour se fait notamment dans les années 1980 : en 1986, David Rumelhart, Geoffrey Hinton et Ronald Williams popularisent l'utilisation de la rétropropagation pour entraîner des réseaux multicouches [3].

La logique mathématique est assez élégante : on calcule une fonction de perte L qui mesure l'erreur, puis on utilise la règle de la chaîne pour déterminer l'effet de chaque paramètre sur cette erreur, avant de modifier les poids dans le sens qui la réduit. C'est précisément ce que résume la descente de gradient :

$$\theta \leftarrow \theta - \eta \nabla L(\theta)$$

Le calcul différentiel et l'optimisation deviennent ainsi vraiment visibles dans l'IA moderne.

Dans les années 1990 et 2000, le machine Learning se développe avec plusieurs familles de modèles : régression, arbres de décision, machines à vecteurs de support, méthodes d'ensemble et réseaux neuronaux. La différence avec l'IA symbolique est importante : le programmeur ne décrit plus nécessairement toutes les règles, il choisit un modèle, une fonction objective et des données, et l'algorithme apprend une partie du comportement recherché.

Ce qui change avec l'apprentissage

IA symbolique : l'humain écrit surtout les règles qui produisent la décision.

Machine Learning : l'humain choisit les données, les variables, le modèle et le critère d'erreur ; les paramètres sont ensuite estimés à partir des exemples.

Deep Learning : une partie des représentations utiles est elle aussi apprise automatiquement, à travers plusieurs couches.

5. Deep Learning, Transformer et modèles de fondation

Le Deep Learning ne naît pas en 2012, mais cette année devient un repère. Alex Krizhevsky, Ilya Sutskever et Geoffrey Hinton présentent AlexNet, un réseau convolutionnel entraîné sur plus d'un million d'images d'ImageNet. Le modèle obtient un gain très net par rapport aux méthodes concurrentes, et montre aussi l'intérêt des GPU pour accélérer l'entraînement [4]. À partir de là, les réseaux profonds deviennent une méthode centrale en vision, puis dans la parole et le langage.

Les réseaux convolutionnels reposent sur une idée mathématique simple : le même petit filtre est appliqué à différentes positions de l'image. Le nombre de paramètres s'en trouve réduit, et des motifs locaux émergent, d'abord des bords ou des textures, puis des structures plus complexes dans les couches suivantes. Le modèle apprend ainsi progressivement ses propres représentations, au lieu de recevoir toutes les caractéristiques à la main.

La génération progresse aussi. En 2014, Ian Goodfellow et ses coauteurs proposent les GAN, où deux réseaux sont mis en compétition : un générateur produit des exemples, un discriminateur essaie de distinguer les vrais des faux [1]. L'idée influencera fortement la génération d'images ; d'autres familles, notamment les modèles de diffusion, prendront ensuite le relais.

Pour le langage, la grande rupture vient en 2017 avec l'article *Attention Is All You Need*, qui propose l'architecture Transformer [5]. Au lieu de traiter les mots uniquement les uns après les autres, le mécanisme d'attention calcule directement quelles parties d'une séquence sont importantes les unes pour les autres. Sous une forme simplifiée, l'attention s'écrit :

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) V$$

Les matrices Q, K et V sont apprises à partir des représentations des mots. Derrière une formule assez compacte se trouve l'un des mécanismes les plus importants de l'IA actuelle.

Cette architecture facilite l'entraînement de très grands modèles sur d'énormes corpus, et une nouvelle manière de construire les systèmes apparaît : on préentraîne un modèle général sur des données très larges, puis on l'adapte à différentes tâches. Stanford propose le terme *foundation model* pour désigner ces modèles qui servent de base à de nombreuses applications [6]. On ne construit ainsi plus forcément un modèle indépendant pour chaque problème.

Les grands modèles de langage illustrent bien ce mouvement. Ils apprennent d'abord à prédire des éléments manquants ou le prochain token dans de très grandes quantités de texte ; une tâche qui paraît simple, mais qui force le modèle à apprendre beaucoup de régularités de langue, de style et de connaissances présentes dans les données. Vient ensuite le post-entraînement : des travaux comme *InstructGPT* montrent en 2022 qu'un modèle peut être ajusté à partir de démonstrations et de préférences humaines pour mieux suivre une instruction [7]. C'est une étape clé pour comprendre comment on est passé d'un modèle qui complète du texte à un assistant avec lequel on peut dialoguer.

6. Où en est l'IA aujourd'hui ?

Depuis quelques années, l'évolution ne consiste plus seulement à faire des modèles plus grands. Les systèmes deviennent aussi multimodaux : ils relient texte, images, audio et parfois vidéo. Une même interface peut lire un document, analyser une image, en discuter le contenu et produire une réponse dans un autre format ; on se rapproche de systèmes plus généraux, sans que cela signifie qu'ils comprennent le monde comme un humain.

Le raisonnement est un autre axe très visible : les modèles récents progressent fortement en mathématiques, en programmation et en résolution de problèmes, au point qu'un système a atteint, selon le *AI Index 2026*, un niveau médaille d'or aux problèmes de l'Olympiade internationale de mathématiques 2025. Le même rapport insiste pourtant sur un phénomène déroutant : les capacités restent très irrégulières, et un modèle capable de résoudre ce genre de problème peut encore échouer sur une tâche beaucoup plus banale, comme lire correctement une horloge analogique [8]. Cette « intelligence en dents de scie » mérite d'être gardée en tête.

On voit également apparaître les agents : des systèmes qui reçoivent un objectif, décomposent la tâche, utilisent des outils, observent un résultat, puis choisissent l'étape suivante, au lieu de se contenter de produire une réponse unique. Les progrès ont été rapides en 2025 sur ce type de tâches, mais les meilleurs agents échouent encore environ une fois sur trois sur certaines évaluations structurées [8] : confier une tâche complète à une IA reste donc plus difficile que lui poser une question isolée.

Le passage au monde physique est plus compliqué encore : en simulation, les robots atteignent des performances très élevées, mais dans une maison réelle les objets changent de position, la lumière varie, et une action ratée peut avoir des conséquences. Le même rapport indique qu'ils ne réussissent encore qu'une faible part des tâches domestiques réelles testées [8], loin des résultats obtenus en environnement contrôlé.

L'IA prend enfin une place croissante dans la recherche scientifique : en biologie, chimie, météorologie, astronomie ou physique, des modèles analysent de grandes quantités de données et accélèrent certaines étapes du travail scientifique. Le rapport Stanford 2026 montre une forte croissance des publications

scientifiques utilisant l'IA, tout en soulignant que les systèmes restent loin de pouvoir reproduire seuls tout le processus d'une recherche [8].

Pendant longtemps, le progrès a surtout été raconté comme une augmentation de la taille des modèles et des données. Aujourd'hui, la compétition se déplace aussi vers le coût, la fiabilité, la rapidité, l'utilisation d'outils et la capacité à mener une tâche réelle jusqu'au bout [8] : le meilleur modèle n'est pas forcément le plus gros, et l'efficacité des algorithmes ainsi que la qualité du post-entraînement comptent de plus en plus.

7. Limites et avenir de l'IA

Les capacités actuelles sont impressionnantes, mais un problème simple demeure : un modèle peut produire une réponse fausse avec la même assurance qu'une réponse correcte. Les hallucinations, les biais liés aux données et la difficulté à évaluer réellement la fiabilité d'un système restent des sujets majeurs. Les benchmarks eux-mêmes vieillissent vite, certains étant saturés quelques mois à peine après leur création [8], ce qui pousse les chercheurs à réinventer sans cesse leurs façons de mesurer les progrès.

Il y a aussi une question de ressources : entraîner et faire fonctionner de grands modèles demande des puces, de l'énergie et beaucoup de données. Les progrès futurs passeront probablement autant par de meilleures méthodes mathématiques que par davantage de calcul : architectures plus efficaces, compression, quantification, meilleures méthodes d'optimisation, données mieux sélectionnées, et modèles spécialisés lorsqu'un système général n'est pas nécessaire.

Pour quelqu'un venant des mathématiques, c'est justement un aspect qui me frappe dans l'IA actuelle. Derrière les interfaces très simples que l'on utilise chaque jour se cachent de l'algèbre linéaire, des probabilités, de l'optimisation, de la géométrie en grande dimension, et de plus en plus de questions autour de la vérification. Les progrès sur le raisonnement mathématique et la démonstration automatique montrent que le lien entre IA et mathématiques n'est pas seulement historique : il continue de se renforcer.

Au-delà de ces limites concrètes, le sujet invite aussi à regarder vers des pistes plus prospectives, plus difficiles à évaluer aujourd'hui.

L'intelligence artificielle générale, ou AGI, désigne un système qui ne serait plus limité à un domaine précis, mais capable de s'adapter à un grand nombre de tâches intellectuelles, un peu comme le ferait un humain [1]. Les modèles actuels deviennent plus polyvalents d'année en année, mais cette polyvalence croissante ne permet pas d'affirmer qu'une telle intelligence générale est déjà atteinte, ni même de dire à quelle échéance elle pourrait l'être.

On parle également d'apprentissage automatique quantique, ou *quantum machine Learning* : un domaine de recherche qui étudie comment des algorithmes quantiques pourraient accélérer ou transformer certaines tâches d'apprentissage [9]. Pour l'instant, cela reste surtout un champ encore jeune, loin d'une technologie déployée dans les usages courants.

Enfin, la question d'une conscience artificielle va plus loin encore. Produire un comportement intelligent, même très convaincant, n'implique pas nécessairement une expérience subjective. Un rapport interdisciplinaire réunissant chercheurs en IA et en sciences de la conscience conclut d'ailleurs qu'aucun système actuel ne semble conscient, sans qu'il existe pour autant d'obstacle de principe à en construire un jour [10]. C'est une question autant philosophique que scientifique, sur laquelle il n'existe aujourd'hui aucun

consensus, et je préfère la mentionner ici avec cette prudence plutôt que de trancher un débat qui reste largement ouvert.

Plus largement, il faut rester prudent face à ce type d'annonces. L'histoire du domaine montre que les périodes d'enthousiasme ont déjà conduit, à plusieurs reprises, à surestimer ce qui était réellement acquis. La question intéressante pour les prochaines années sera sans doute moins « quand l'IA deviendra-t-elle générale, quantique ou consciente ? » que « quelles capacités deviennent fiables, dans quelles conditions, et pour quels usages ? »

Conclusion

L'intelligence artificielle actuelle est le résultat d'une construction longue. Il a d'abord fallu formaliser la logique et le calcul, imaginer des machines programmables, comprendre les limites du calcul, puis apprendre à ajuster automatiquement des modèles à partir de données. Les réseaux de neurones, la rétropropagation, les GPU, les Transformers et le préentraînement à grande échelle ont ensuite accéléré cette évolution.

Ce parcours montre surtout que l'IA avance par changements de représentation et de méthode : des règles écrites à la main, on est passé à des modèles qui apprennent leurs paramètres, puis à des modèles de fondation adaptables à de nombreux usages. Aujourd'hui, l'enjeu se déplace encore vers le raisonnement, la multimodalité, les agents et l'utilisation de l'IA dans le monde réel.

C'est aussi ce qui me pousse à poursuivre dans cette direction. Venant des mathématiques, je retrouve dans cette histoire une continuité qui me parle : la même logique, la même algèbre, les mêmes probabilités que j'ai étudiées se prolongent aujourd'hui dans des systèmes bien plus vastes. Comprendre cette histoire m'aide à mieux lire les annonces actuelles : tout n'est pas entièrement nouveau, et tout n'est pas non plus déjà résolu. Pour suivre un domaine qui évolue aussi vite, connaître les idées qui se trouvent derrière les outils me paraît finalement aussi important que savoir les utiliser.

Sources principales

- [1] Russell, S. J. & Norvig, P. (2021). Artificial Intelligence: A Modern Approach, 4e édition. Pearson. Chapitres historiques et fondements de l'IA.
- [2] Turing, A. M. (1950). « Computing Machinery and Intelligence ». Mind, 59(236), 433-460. <https://doi.org/10.1093/mind/LIX.236.433>
- [3] Rumelhart, D. E., Hinton, G. E. & Williams, R. J. (1986). « Learning representations by back-propagating errors ». Nature, 323, 533-536. <https://doi.org/10.1038/323533a0>
- [4] Krizhevsky, A., Sutskever, I. & Hinton, G. E. (2012). « ImageNet Classification with Deep Convolutional Neural Networks ». NeurIPS 25.
- [5] Vaswani, A. et al. (2017). « Attention Is All You Need ». arXiv:1706.03762.
- [6] Bommasani, R. et al. (2021). « On the Opportunities and Risks of Foundation Models ». Stanford CRFM. <https://crfm.stanford.edu/report>
- [7] Ouyang, L. et al. (2022). « Training language models to follow instructions with human feedback ». arXiv:2203.02155.
- [8] Stanford Institute for Human-Centered AI (2026). AI Index Report 2026, notamment les chapitres Technical Performance, Responsible AI et Science. <https://hai.stanford.edu/ai-index/2026-ai-index-report>
- [9] Biamonte, J., Wittek, P., Pancotti, N., Rebentrost, P., Wiebe, N. & Lloyd, S. (2017). « Quantum machine learning ». Nature, 549, 195-202. <https://doi.org/10.1038/nature23474>
- [10] Butlin, P., Long, R., Elmoznino, E., Bengio, Y. et al. (2023). « Consciousness in Artificial Intelligence: Insights from the Science of Consciousness ». arXiv:2308.08708.